DataMate — pipeline suy luận chi tiết

*LLM chỉ viết SQL; **DuckDB** tính ra con số. Không đủ phiếu thì **abstain** (0 điểm) thay vì đoán sai (−1).*

A · Một lần cho mỗi tiệm

views.py · debts.py — nháp bởi LLM, kiểm trên dữ liệu

1 Nạp dữ liệu
`ingest.py` → DuckDB
đoán header, chuẩn hoá ngày, số tiền, tên hàng (canon)
+ profile từng cột

2 Nháp view
K = 8 câu SELECT
model gốc, thinking 6k
map bảng thô → cột chuẩn
`order_id, qty, amount…`

3 Kiểm trên dữ liệu
`catalog·time·split·qty`
nháp lỗi → **sửa ≤ 2 lượt**
chưa có đa số → thêm 1 vòng 8 nháp

4 Chọn theo đa số
cùng fingerprint kết quả
≥ K/4 nháp đồng ý mới dùng
qty lệch giá > 3× → quy đổi đơn vị theo giá

5 Lớp công nợ
cùng công thức: 8 nháp, kiểm, sửa, bỏ phiếu
`debt_at(day)`
`debt_new · debt_repaid`

6 Ngữ cảnh tiệm
README + SCHEMA
+ CANONICAL VIEWS
`v_sales · v_orders`
+ macro công nợ

ngữ cảnh tiệm dùng chung cho mọi câu của tiệm

B · Mỗi câu hỏi

pipeline.py: build_chats → sample → decide

share < 0.75 hoặc câu công nợ → +4 mẫu thinking (16k token), bỏ qua khi chạy chậm tiến độ

1 Câu hỏi
*"doanh thu **tháng trước**?"*
`as_of_date`
+ rulebook đầy đủ
không cắt bớt luật

2 Gợi ý
khung ngày theo as_of_date
giá trị khớp tên trong câu
gợi ý theo dạng câu
kỳ ngoài dữ liệu? `(oor)`

3 2 prompt
`SYSTEM` + rulebook
prompt 2: + **4 ví dụ**
few-shot giống câu hỏi
mở đầu: `Notes:`

4 8 mẫu SQL
Qwen3.5-9B + LoRA
vLLM fp8, T = 0.7
4 mẫu × 2 prompt
`TYPE: … + SQL`

5 Chạy DuckDB
chỉ đọc, 1 luồng, 6 GB
thiếu TYPE → điền TYPE
lỗi → **sửa ≤ 2 lượt**
có lỗi kèm gợi ý sửa

6 Bỏ phiếu
gộp đáp án như scorer
câu công nợ: chỉ mẫu gọi macro được bầu
share = đồng ý / tổng

share ≥ 0.5 → **trả lời**

thấp · 0 · rỗng → **abstain**

kỳ ngoài dữ liệu → **unanswerable**

C · Docker

`predict.sh`
1 tiến trình / GPU, chia tiệm

`--deadline`
tự dừng ở 5 h 50 (giới hạn 6 h)

`submission.jsonl`
ghi lại sau mỗi tiệm

`logs/<id>.json`
thinking · code · output